CHƯƠNG 2 CÁC KỸ THUẬT XỬ LÝ ẢNH VÀ HỌC SÂU TRONG CHẨN ĐOÁN BỆNH

Trong chương này, chúng ta sẽ xem xét ba phần chính. Phần đầu tiên tập trung vào giới thiệu các vấn đề xử lý ảnh. Phần thứ hai giới thiệu các mô hình học sâu, đặc biệt là những kỹ thuật phổ biến được áp dụng trong xử lý ảnh y khoa. Phần thứ ba tập trung vào giới thiệu các mô hình chú ý trong lĩnh vực thị giác máy tính.

2.1 Các vấn đề cơ bản về xử lý ảnh

Xử lý ảnh là một lĩnh vực quan trọng trong thị giác máy tính và là nền tảng cho nhiều nghiên cứu trong lĩnh vực này. Quá trình xử lý ảnh có hai nhiệm vụ cơ bản là cải thiện chất lượng thông tin hình ảnh và xử lý dữ liệu để cung cấp cho các quá trình khác bao gồm việc áp dụng thị giác vào điều khiển.

2.1.1 Biến đổi ảnh

Biến đổi ảnh trong xử lý ảnh là quá trình thay đổi cấu trúc, thông tin hoặc hình dạng của ảnh để tạo ra phiên bản mới với mục đích cải thiện, điều chỉnh hoặc thay đổi nội dung của ảnh gốc. Các phương pháp biến đổi ảnh có thể áp dụng một loạt các thao tác hình học và xử lý pixel để thay đổi ảnh. Một số phương pháp biến đổi ảnh phổ biến:

Thay đổi kích thước: bằng cách tăng hoặc giảm số pixel hoặc tỉ lệ ảnh.

Xoay và lật: bằng cách quay ảnh xung quanh một điểm chốt hoặc lật ảnh theo các trục hoặc chiều khác nhau.

Đối xứng: bằng cách lật ngược ảnh theo trục hoặc chiều cụ thể.

2.1.2 Một số kỹ thuật xử lý ảnh

2.1.2.1 Kỹ thuật lọc nhiễu

Kỹ thuật lọc nhiễu BM3D (Block-matching and 3D filtering) là một kỹ thuật tiên tiến được áp dụng để giảm nhiễu trong ảnh số mà không gây mất mát quá nhiều chi tiết quan trọng.

Dưới đây là các bước cơ bản trong phương pháp BM3D để khử nhiễu ảnh:

- Phân nhóm khối (Grouping): ảnh gốc được chia thành các khối con trùng lắp và chồng chéo. Các khối con này được nhóm lại thành các nhóm khối có cùng vị trí tương ứng trong các khối con của ảnh. Mỗi nhóm khối chứa các khối con tương tự nhau.

- Tìm khối tham chiếu và khớp khối (Matching): trong mỗi nhóm khối, một khối con được chọn làm khối tham chiếu và các khối con khác được so sánh với khối tham chiếu. Các khối con khác được khớp với khối tham chiếu dựa trên sự tương đồng của nội dung. Quá trình này giúp tìm ra các khối tương tự và các mẫu nhiễu chung trong nhóm khối.

- Biến đổi phổ 3D (3D Transform): Các khối dự đoán từ bước trước được biến đổi bằng các biến đổi phổ 3D, chẳng hạn như biến đổi cosine rời rạc. Quá trình biến đổi phổ 3D giúp phân tách các thành phần tương tự và nhiễu trong các khối.

- Lọc thông tin 3D (3D Filtering): Các thông tin biến đổi phổ 3D được lọc để giảm nhiễu. Trong giai đoạn này, một bộ lọc phù hợp được áp dụng để giảm thiểu nhiễu trong các khối và tạo ra các khối đã được lọc.

- Tổng hợp (Aggregation): Các khối đã được lọc từ các nhóm khối được tổng hợp lại để tạo ra ảnh đã được khử nhiễu cuối cùng. Quá trình này giúp tạo ra hình ảnh có chất lượng tốt hơn và giảm thiểu nhiễu.

BM3D đã được chứng minh là một phương pháp mạnh mẽ trong việc khử nhiễu ảnh, cho phép giảm nhiễu hiệu quả trong hình ảnh và giữ lại các chi tiết quan trọng, giúp cải thiện chất lượng ảnh.

2.1.2.2 Kỹ thuật tăng cường độ tương phản

Tăng cường độ tương phản của ảnh có thể được thực hiện bằng nhiều phương pháp kỹ thuật khác nhau. Dưới đây là một số kỹ thuật được sử dụng phổ biến:

CLAHE (Contrast Limited Adaptive Histogram Equalization) là một phương pháp cải

thiện độ tương phản của ảnh xám bằng cách áp dụng cân bằng lược đồ màu cho các vùng nhỏ hơn trong ảnh.

Phương pháp CLAHE chia ảnh ban đầu thành các ô nhỏ hơn gọi là ô con và áp dụng histogram equalization cho mỗi ô con này. Tuy nhiên, để tránh tăng nhiễu (noise) trong ảnh, CLAHE giới hạn sự thay đổi độ sáng trong mỗi ô con bằng cách áp dụng một ngưỡng tối đa.

Quá trình CLAHE diễn ra như sau:

- Chia ảnh ban đầu thành các ô con: Ảnh ban đầu được chia thành các ô con không chồng lấp, mỗi ô con có kích thước nhất định. Kích thước của ô con được chọn sao cho nó nhỏ hơn kích thước của toàn bộ ảnh và phù hợp với tính chất của bức ảnh.

- Tính toán histogram cho mỗi ô con: Đối với mỗi ô con, histogram của nó được tính toán, biểu thị phân bố độ sáng của các mức xám trong ô con đó.

- Áp dụng histogram equalization cho mỗi ô con: Histogram của mỗi ô con được cân bằng để có phân bố đồng đều của các mức xám. Quá trình cân bằng histogram này đảm bảo rằng độ tương phản được tăng cường trong mỗi ô con.

- Giới hạn sự thay đổi độ sáng trong mỗi ô con: Để tránh tăng nhiễu (noise) trong ảnh, CLAHE giới hạn sự thay đổi độ sáng trong mỗi ô con bằng cách áp dụng một ngưỡng (threshold) tối đa. Điều này đảm bảo rằng chỉ có một số hạn chế về tối đa độ sáng được tăng trong mỗi ô con.

- Ghép các ô con lại thành ảnh kết quả: Sau khi áp dụng cân bằng histogram và giới hạn độ sáng trong mỗi ô con, các ô con được ghép lại thành ảnh kết quả cuối cùng.

Phương pháp CLAHE giúp cải thiện độ tương phản của ảnh bằng cách tăng cường đặc trưng và giảm hiện tượng mất mát thông tin do sự tập trung quá mức độ sáng vào một số vùng cụ thể. Nó được sử dụng rộng rãi trong xử lý ảnh để cải thiện chất lượng ảnh và tạo ra hình ảnh với độ tương phản tốt hơn.

Bộ lọc EDGE_ENHANCE_MORE là một trong các bộ lọc trong xử lý ảnh, được sử

dụng để tăng cường độ tương phản của các cạnh trong ảnh. Nó là một bộ lọc thông qua một ma trận (kernel) để thực hiện phép tính convolution trên ảnh đầu vào.

Bộ lọc hoạt động bằng cách tăng độ tương phản của các cạnh trong ảnh. Nó làm nổi bật các biên và đường viền trong ảnh bằng cách tăng độ chênh lệch giữa các pixel gần nhau trên các cạnh.

Để áp dụng bộ lọc, ta thực hiện phép tính tích chập giữa ma trận kernel của bộ lọc và ma trận ảnh đầu vào. Ma trận kernel của bộ lọc thường có kích thước 3x3. Trong quá trình tích chập, kernel này được trượt qua từng vị trí của ma trận ảnh. Tại mỗi vị trí, các giá trị pixel lân cận được nhân với các giá trị tương ứng trong kernel và được tổng hợp lại để tạo ra giá trị mới cho pixel đó trong ảnh kết quả.

2.1.3 Trích chọn biểu diễn đặc trưng ảnh

Việc trích chọn đặc trưng ảnh là quá trình quan trọng trong xử lý ảnh, nhằm rút trích thông tin quan trọng từ ảnh để sử dụng trong các thuật toán. Đặc trưng ảnh đại diện cho các thuộc tính và đặc điểm độc đáo của ảnh, giúp chúng ta phân biệt các đối tượng trong ảnh một cách hiệu quả.

Có nhiều loại đặc trưng ảnh thông thường được sử dụng, bao gồm:

Đặc trưng hình dạng: đây là việc tính toán các thuộc tính liên quan đến hình dạng của đối tượng trong ảnh, như diện tích, chu vi, hướng, đường kính, số lượng đỉnh, và nhiều thông tin khác. Đặc trưng hình dạng thường được áp dụng để phát hiện và phân loại các đối tượng trên ảnh.

Đặc trưng màu sắc: việc tính toán các thuộc tính liên quan đến màu sắc của ảnh, bao gồm độ sáng trung bình, phân phối màu sắc, độ tương phản, và điểm màu trung bình. Đặc trưng màu sắc được sử dụng phổ biến để phân loại, tìm kiếm và nhận dạng các đối tượng trong ảnh.

Đặc trưng cạnh: đặc trưng này liên quan đến việc phát hiện và trích xuất các đường biên và cạnh trong ảnh. Các thuộc tính như độ dốc, biên độ, và hướng của cạnh được sử dụng để phân tích và nhận dạng hình ảnh.

Các đặc trưng ảnh này có vai trò quan trọng trong nhiều ứng dụng xử lý ảnh, bao gồm nhận dạng, phân loại, tìm kiếm và xử lý tự động dữ liệu hình ảnh.

Có nhiều kỹ thuật trích chọn đặc trưng ảnh, một kỹ thuật mạnh mẽ trong việc trích chọn đặc trưng ảnh là phương pháp mạng nơ-ron tích chập (CNN). CNN sử dụng các tầng đặc trưng để tìm ra các đặc trưng quan trọng trong ảnh thông qua việc áp dụng bộ lọc và hàm kích hoạt tương ứng. Đặc biệt, CNN thể hiện hiệu suất cao trong việc xử lý ảnh có kích thước lớn và độ phức tạp cao.

CNN là một kỹ thuật mạnh mẽ trong trích chọn đặc trưng ảnh vì nó có khả năng tự động học các đặc trưng quan trọng từ dữ liệu ảnh và có khả năng tổng hợp thông tin không gian trong ảnh. Kỹ thuật này được sử dụng rộng rãi trong các bài toán phân loại và nhận dạng đối tượng trên ảnh.

2.2 Các mô hình học sâu phổ biến trong xử lý ảnh y khoa

Trong lĩnh vực y khoa, có nhiều mô hình học sâu phổ biến được sử dụng để giải quyết các bài toán như phân loại bệnh, phát hiện bệnh, dự đoán kết quả điều trị và nhiều ứng dụng khác. Dưới đây là một số mô hình học sâu phổ biến trong y khoa:

2.2.1 Mô hình mạng VGG

Mô hình VGG [17] là một mô hình mạng nơ-ron được phát triển bởi nhóm nghiên cứu tại Đại học Oxford, Anh Quốc, với mục tiêu giải quyết bài toán phân loại ảnh với độ chính xác cao. Mô hình VGG đã được trình bày trong bài báo "Very Deep Convolutional Networks for Large-Scale Image Recognition" tại hội nghị CVPR 2014.

Mạng VGG được gồm hai phần chính: phần đầu gồm các lớp tích chập và lớp gộp, trong khi phần thứ hai bao gồm các lớp kết nối đầy đủ.

Lớp tích chập là một phép tính toán trên ảnh để tìm kiếm các đặc trưng cục bộ nhất định. Lớp tích chập trong VGG sử dụng các lõi tích chập kích thước nhỏ (3x3) liên tiếp nhau để tính toán thông tin trong các cửa sổ cục bộ của ảnh. Ví dụ, mỗi lõi có thể tìm kiếm các cạnh, vòng tròn, hoặc đường chéo trong các vùng nhỏ của ảnh. Lớp tích

chập cũng sử dụng một hàm kích hoạt, ví dụ như ReLU để tạo ra các đặc trưng phi tuyến tính cho mạng.

Lớp gộp được dùng để thu nhỏ kích thước của các đặc trưng trung gian trong quá trình tích chập. Việc làm này có nhiều lợi ích, ví dụ như giảm tải tính toán, tạo ra các đặc trưng bền vững hơn với nhiễu và giúp mô hình tổng quát hóa tốt hơn cho các tác vụ phân loại ảnh. Lớp gộp có thể được phân thành hai loại phổ biến: max pooling và average pooling. Trong mô hình VGG, lớp gộp sẽ lấy giá trị lớn nhất hoặc giá trị trung bình trong các vùng của đặc trưng trung gian.

Các lớp tích chập và lớp gộp được sử dụng theo chuỗi liên tiếp nhau trong mô hình VGG nhằm xử lý thông tin hình ảnh và tạo ra các đặc trưng hiển thị cho việc phân loại ảnh.

Lớp kết nối đầy đủ trong mô hình VGG, được sử dụng để phân loại ảnh vào các lớp nhãn. Sau khi thông tin của ảnh được trích xuất thông qua chuỗi các lớp tích chập và lớp giảm mẫu, các đặc trưng này được điều chỉnh về kích thước bằng cách sử dụng lớp phẳng hóa và đưa vào lớp kết nối đầy đủ. Lớp kết nối đầy đủ thường được miêu tả như một lớp mạng nơ-ron tiêu chuẩn, trong đó mỗi nơ-ron trong lớp kết nối đầy đủ kết nối với tất cả các nơ-ron của lớp trước đó. Các nơ-ron trong lớp kết nối đầy đủ thường được kích hoạt bằng các hàm kích hoạt như ReLU hoặc softmax, giúp phân loại ảnh vào các lớp nhãn tương ứng.

Trong kiến trúc VGG, lớp kết nối đầy đủ được sử dụng với một số lượng nơ-ron khác nhau tùy thuộc vào từng bài toán phân loại cụ thể. Thông thường, lớp kết nối đầy đủ cuối cùng có số lượng nơ-ron bằng số lớp nhãn trong bài toán phân loại. Ví dụ, nếu có 100 lớp nhãn trong bài toán phân loại ảnh, lớp kết nối đầy đủ cuối cùng sẽ có 100 nơ-ron tương ứng.

Mô hình VGG được xây dựng với nhiều kiến trúc mạng khác nhau, có số lượng lớp tích chập và lớp kết nối đầy đủ khác nhau. Tuy nhiên, trong VGG, có hai kiến trúc mạng phân loại ảnh được sử dụng rộng rãi là VGG16 và VGG19. Mô hình mạng VGG16 là một kiến trúc mạng sâu được sử dụng phổ biến để phân loại ảnh. Nó bao

gồm tổng cộng 16 lớp mạng, gồm các lớp tích chập và lớp kết nối đầy đủ. Trong kiến trúc này, lớp kết nối đầy đủ cuối cùng có số lượng nơ-ron bằng với số lượng lớp nhãn trong bộ dữ liệu ImageNet, tức là 1000 lớp. Điều này cho phép mô hình VGG16 có khả năng phân loại ảnh vào 1000 lớp khác nhau trong bộ dữ liệu ImageNet [18].

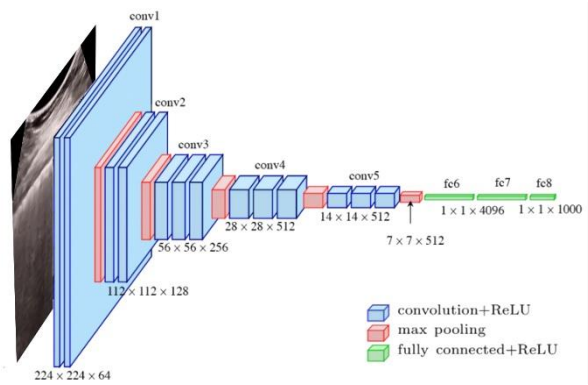

Hình 2.1 Mô hình mạng VGG16

Cụ thể, kiến trúc mạng VGG16 sử dụng 13 lớp tích chập với số lượng bộ lọc khác nhau, theo thứ tự là 64, 64, 128, 128, 256, 256, 256, 512, 512, 512, 512, 512 và 512. Trong đó, lớp tích chập đầu tiên sử dụng một bộ lọc 3 x 3 với độ sâu 3 (3 kênh), kế tiếp các lớp tích chập sử dụng 2-3 bộ lọc 3 x 3 với độ sâu tăng dần. Các lớp tích chập đến lớp thứ 4 sử dụng một bộ lọc 3 x 3, và lớp tích chập từ lớp thứ 5 trở đi sử dụng hai bộ lọc 3 x 3 liên tiếp nhau để tính toán. Mỗi lớp tích chập trong các lớp đầu tiên của VGG16 được đánh số theo thứ tự convN, trong đó N là số thứ tự của lớp tích chập đó (hình 2.1), và các lớp tích chập sử dụng hàm kích hoạt là ReLU. Sau đó, thông tin được đưa vào ba lớp kết nối đầy đủ với số lượng nơ-ron lần lượt là 4096, 4096 và 1000. Các nơ-ron trong các lớp kết nối đầy đủ được kích hoạt bằng hàm ReLU, và lớp kết nối cuối cùng sử dụng hàm softmax để tạo ra xác suất dự đoán cho từng lớp nhãn. Mô hình VGG16 được huấn luyện trên tập dữ liệu phổ biến là ImageNet [18], với hơn 1 triệu hình ảnh đào tạo và xác nhận, để dự đoán các lớp nhãn cho bức ảnh. Với số lượng lớp tích chập đủ lớn và các bộ lọc nhỏ liên tiếp nhau, mô hình VGG16 cho kết quả với độ chính xác cao khi phân loại ảnh trên các bộ dữ liệu ảnh phổ biến.

Mô hình mạng VGG19 là một mô hình mạng sâu được sử dụng để phân loại hình

ảnh, là phiên bản được cải tiến từ mô hình VGG16, bao gồm tổng cộng 19 lớp mạng. Cụ thể, kiến trúc mạng VGG19 tương tự như kiến trúc VGG16, với 16 lớp tích chập (sử dụng các bộ lọc 3 x 3 và lớp gộp tối đa có kích thước 2x2) và 3 lớp kết nối đầy đủ, nhưng bao gồm thêm một lớp tích chập với 512 bộ lọc 3 x 3 trước khi đến các lớp kết nối đầy đủ cuối cùng. Trong 3 lớp kết nối đầy đủ cuối cùng, hai lớp đầu tiên có 4096 nơ-ron mỗi lớp và lớp thứ ba có số lượng nơ-ron bằng với số lượng lớp nhãn của bộ dữ liệu ImageNet (1000 lớp) [18].

2.2.2 Mô hình mạng ResNet

Mô hình ResNet [19] là một mạng nơ-ron sâu được giới thiệu vào năm 2015 bởi các nhà nghiên cứu tại Microsoft Research. Được phát triển nhằm giải quyết vấn đề của việc xây dựng các mạng nơ-ron sâu với số lượng lớp lớn gây khó khăn trong việc tối ưu hóa. Mô hình ResNet sử dụng kỹ thuật kết nối bỏ qua (skip connection) để đối phó với hiện tượng "vanishing gradient" và giúp mạng nơ-ron sâu có khả năng học các đặc trưng cấp cao. Điều này đảm bảo rằng các thông tin quan trọng từ các lớp trước đó được truyền qua mạng một cách hiệu quả, giúp cải thiện khả năng học và tối ưu của mạng ResNet.

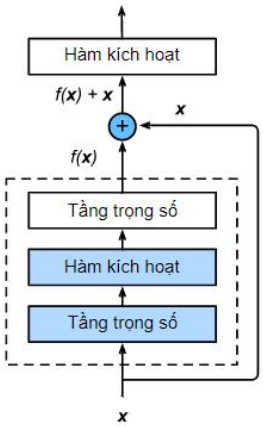

Hình 2.2 Kiến trúc khối phần dư

ResNet có cấu trúc tương tự như VGG với nhiều lớp xếp chồng làm mô hình sâu hơn và cũng là mạng nơ-ron tích chập gồm nhiều khối phần dư nhỏ (hình 2.2). Ý tưởng của một khối phần dư là khi đầu vào x đi qua một số lớp, chúng ta nhận được $f(x)$ sau đó thêm x vào $h(x) = f(x) + x$. Mô hình dễ học hơn bằng cách thêm các tính năng từ

lớp trước. Hiện nay, có nhiều biến thể của kiến trúc ResNet với số lượng lớp khác nhau, ví dụ như ResNet18, ResNet34, ResNet50, ResNet101 và nhiều hơn nữa. Tên gọi ResNet được theo sau bởi một số chỉ số, đại diện cho số lượng lớp trong mạng. Số lớp càng cao, mạng càng sâu và có khả năng học các đặc trưng phức tạp.

Mô hình mạng ResNet18 là một trong những kiến trúc mạng trong mô hình ResNet, bao gồm 18 lớp mạng. Có 4 lớp tích chập trong mỗi khối (không tính lớp tích chập 1×1). Cộng thêm lớp tích chập đầu tiên và lớp kết nối đầy đủ cuối cùng, mô hình có tổng cộng 18 tầng. (hình 2.3)

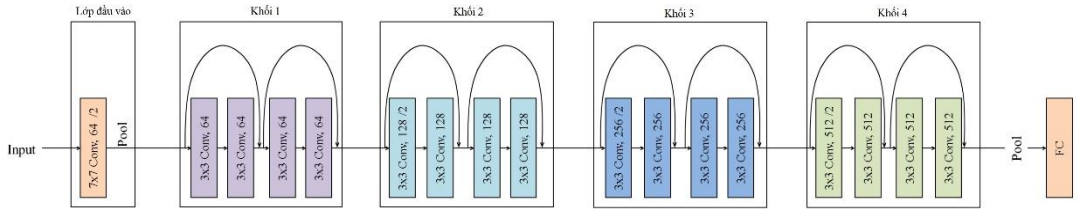

Hình 2.3 Kiến trúc mạng ResNet18

Cụ thể, kiến trúc đúng của ResNet-18 được miêu tả như sau:

Lớp đầu vào: một lớp tích chập với 64 bộ lọc, kích thước bộ lọc 7x7, stride=2 và same padding, theo sau đó là một lớp ReLU và một lớp MaxPooling với kích thước kernel là 3x3 và stride=2.

Khối 1 gồm 4 lớp tích chập với bộ lọc có kích thước 3x3, số lượng bộ lọc là 64. Mỗi lớp tích chập được ngăn cách bởi một lớp ReLU và cuối cùng là kết nối bỏ qua.

Khối 2 gồm 4 lớp tích chập với bộ lọc có kích thước 3x3, số lượng bộ lọc là 128. Mỗi lớp tích chập được ngăn cách bởi một lớp ReLU và cuối cùng là kết nối bỏ qua.

Khối 3 gồm 4 lớp tích chập với bộ lọc có kích thước 3x3, số lượng bộ lọc là 256. Mỗi lớp tích chập được ngăn cách bởi một lớp ReLU và cuối cùng là kết nối bỏ qua.

Khối 4 gồm 4 lớp tích chập với bộ lọc có kích thước 3x3, số lượng bộ lọc là 512. Mỗi lớp tích chập được ngăn cách bởi một lớp ReLU và cuối cùng là kết nối bỏ qua.

Cuối cùng, mô hình bao gồm một lớp kết nối đầy đủ với 1000 nơ-ron, là số lượng lớp

đầu ra của dữ liệu ImageNet.

2.3 Các cơ chế chú ý

Cơ chế chú ý [20] là một phương pháp quan trọng được áp dụng trong học sâu, đặc biệt trong bài toán thị giác máy tính, nhằm giúp mô hình tập trung vào các vùng quan trọng trong ảnh hoặc video để nhận diện đối tượng, vật thể và mối quan hệ giữa chúng một cách chính xác.

Các cơ chế chú ý có thể được phân loại thành: chú ý không gian (spatial attention), chú ý kênh (channel attention), chú ý hỗn hợp (mixed attention) và tự chú ý (self-attention).

Cơ chế chú ý không gian (spatial attention) là một phương pháp trong học sâu tập trung vào các đặc trưng cục bộ của ảnh, tức là các vùng trong ảnh có giá trị cao hơn so với các vùng khác. Trong mô hình CNN, cơ chế chú ý không gian được áp dụng để tập trung vào các khu vực quan trọng trong ảnh. Cơ chế chú ý không gian đạt được điều này bằng cách sử dụng các phép tích chập để tạo ra các bản đồ đặc trưng. Các bản đồ đặc trưng này sẽ có giá trị cao tại các vị trí tương ứng với các đặc trưng quan trọng trong ảnh. Sau đó, các khu vực quan trọng này sẽ được kích hoạt thông qua một cơ chế chú ý, giúp tập trung vào những vùng đó trong quá trình xử lý tiếp theo.

Cơ chế chú ý kênh (channel attention) là một phương pháp khác trong học sâu tập trung vào các kênh đặc trưng của ảnh. Thay vì tập trung vào các vùng cụ thể trong ảnh, cơ chế chú ý kênh tìm hiểu và đánh dấu các kênh đặc trưng quan trọng. Để thực hiện cơ chế chú ý kênh, các bộ lọc tích chập được sử dụng nhằm tìm ra các đặc trưng quan trọng trong từng kênh đặc trưng. Các kênh đặc trưng quan trọng này sau đó được kết hợp lại để tạo ra một bản trích xuất cuối cùng. Quá trình này giúp tập trung vào các thông tin quan trọng trong các kênh đặc trưng và cải thiện khả năng quyết định của mô hình.

Cơ chế chú ý hỗn hợp hay còn gọi với tên Mô-đun chú ý khối tích chập CBAM [21]. Cơ chế CBAM là một phương pháp kết hợp cả cơ chế chú ý không gian và cơ chế chú ý kênh để tạo ra một khối chú ý hiệu quả. Trong CBAM, quá trình chú ý kênh

được thực hiện trước, sau đó tiếp tục với quá trình chú ý không gian. Hình 2.4 cho thấy điều này.

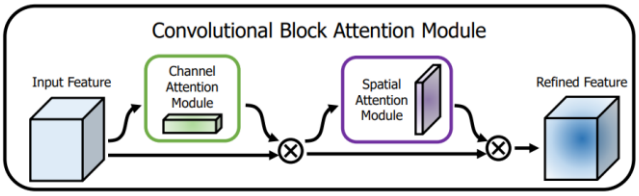

Hình 2.4 Một khối CBAM

CBAM thường được thêm vào sau các khối tích chập trong mạng nơ-ron tích chập, thay vì thay thế các khối tích chập. Các khối CBAM này giúp mô hình tập trung vào các vùng quan trọng của đầu vào thông qua việc chú ý đến không gian và kênh đặc trưng của ảnh. Sau khi tính toán, các khối CBAM này sinh ra các trọng số được áp dụng vào các giá trị tích chập đã tính được từ khối trước đó để tạo các đặc trưng mới cho mô hình. Quá trình chú ý tổng thể được thể hiện qua công thức (2-1) sau:

$$\begin{aligned} \mathbf{F}' &= \mathbf{M}_c(\mathbf{F}) \otimes \mathbf{F}, \\ \mathbf{F}'' &= \mathbf{M}_s(\mathbf{F}') \otimes \mathbf{F}' \end{aligned} \tag{2-1}$$

Trong đó $\otimes$ biểu thị phép nhân giữa các phần tử tương ứng. $\mathbf{F}'$ biểu thị kết quả của phép nhân bản đồ đặc trưng với bản đồ chú ý kênh và $\mathbf{F}''$ là đầu ra tinh chỉnh cuối cùng. Phần sau đây mô tả tổng quan về từng mô-đun chú ý.

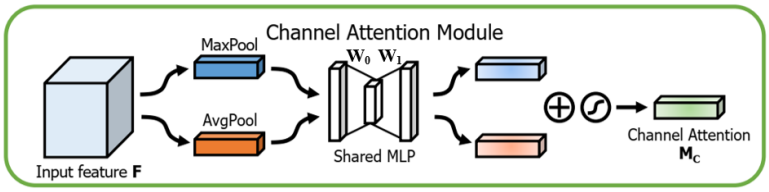

Hình 2.5 Mô-đun chú ý kênh

Mô-đun chú ý kênh (hình 2.5 cho thấy mô-đun chú ý kênh). Cả gộp tối đa (*MaxPool*) và gộp trung bình (*AvgPool*) đều được sử dụng để tạo ra hai bộ mô tả ngữ cảnh không gian khác nhau: $\mathbf{F}^c_{avg}$ và $\mathbf{F}^c_{max}$, đại diện cho các tính năng gộp tối đa và tính năng gộp trung bình. Sau đó, cả hai được chuyển tiếp đến lớp chia sẻ MLP để tạo các tính năng

đầu ra, sau đó được hợp nhất bằng cách sử dụng phép tính tổng theo phần tử $\oplus$. Cuối cùng tổng hợp nhất của cả hai được gửi đến hàm sigmoid σ. Để giảm tài nguyên tham số, kích thước ẩn của MLP được đặt thành $\mathbb{R}^{C/r \times 1 \times 1}$, trong đó r là tỷ lệ giảm. Giả sử $\mathbf{W_0} \in \mathbb{R}^{C/r \times C}$ và $\mathbf{W_1} \in \mathbb{R}^{C \times C/r}$ lần lượt là các trọng số MLP, xem phương trình (2-2):

$$\begin{aligned}\mathbf{M_c}(\mathbf{F}) &= \sigma(MLP(AvgPool(\mathbf{F})) + MLP(MaxPool(\mathbf{F}))) \\ &= \sigma\left(\mathbf{W_1}\left(\mathbf{W_0}\left(\mathbf{F}^{\mathbf{c}}_{\mathbf{avg}}\right)\right) + \mathbf{W_1}\left(\mathbf{W_0}\left(\mathbf{F}^{\mathbf{c}}_{\mathbf{max}}\right)\right)\right),\end{aligned} \tag{2-2}$$

Lưu ý rằng các trọng số $\mathbf{W_0}$ và $\mathbf{W_1}$, được chia sẻ cho cả hai đầu vào (gộp tối đa và gộp trung bình) và chức năng kích hoạt ReLU được theo sau bởi $\mathbf{W_0}$.

Mô-đun chú ý không gian là một bước bổ sung cho mô-đun chú ý kênh trước đó. Tổng hợp trung bình và tổng hợp tối đa được áp dụng cho bản đồ kích hoạt được tinh chỉnh theo kênh $\mathbf{F}'$. Cả gộp trung bình và gộp tối đa đều là bản đồ kích hoạt hai chiều: $\mathbf{F}^{\mathbf{s}}_{\mathbf{avg}} \in \mathbb{R}^{1 \times H \times W}$ và $\mathbf{F}^{\mathbf{s}}_{\mathbf{max}} \in \mathbb{R}^{1 \times H \times W}$. Sau đó, bản đồ kích hoạt được nối được chuyển thành một tích chập có kích thước 7×7 tiêu chuẩn $f^{7\times7}$ và theo sau là một hàm sigmoid σ. Quá trình tính toán thể hiện ở phương trình (2-3) và hình 2.6 thể hiện mô-đun chú ý không gian:

$$\begin{aligned}\mathbf{M_s}(\mathbf{F}) &= \sigma\left(f^{7\times7}([AvgPool(\mathbf{F}); \max Pool(\mathbf{F})])\right) \\ &= \sigma\left(f^{7\times7}\left(\left[\mathbf{F}^{\mathbf{s}}_{\mathbf{avg}}; \mathbf{F}^{\mathbf{s}}_{\mathbf{max}}\right]\right)\right)\end{aligned} \tag{2-3}$$

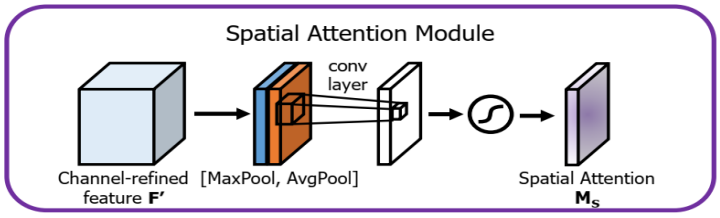

Hình 2.6 Mô-đun chú ý không gian

Tổng quát, *Mô-đun chú ý kênh* sử dụng mối quan hệ giữa các kênh của các tính năng để tạo bản đồ chú ý của kênh. Vì mỗi kênh của bản đồ tính năng được coi là bộ phát hiện tính năng, nên sự chú ý của kênh tập trung vào "điều gì - what" có ý nghĩa đối với đầu vào. *Mô-đun chú ý không gian* sử dụng mối quan hệ không gian giữa các tính

năng để tạo bản đồ chú ý không gian. Không giống như mô-đun chú ý kênh, sự chú ý về không gian tập trung vào "nơi - where" là một phần thông tin bổ sung cho mô-đun chú ý kênh.

Cơ chế tự chú ý (self attention): phương pháp này giúp cho mô hình tập trung vào các phần quan trọng của đầu vào để tạo ra một đạo hàm tổng quát cho mô hình. Cơ chế tự chú ý là một trong những phương pháp quan trọng và đã được áp dụng rộng rãi trong các mô hình transformer.

2.4 Các phương pháp đánh giá hiệu suất mô hình

2.4.1 Confusion Matrix

Confusion Matrix [22] là một công cụ quan trọng trong việc đánh giá kết quả của các bài toán phân loại hình ảnh. Nó cung cấp một cái nhìn tổng quan về độ chính xác và độ bao phủ của từng lớp phân loại, đồng thời giúp tính toán các chỉ số đánh giá khác nhau dựa trên sự kết hợp của các giá trị dự đoán và thực tế. Xem bảng 2.1 dưới.

Bảng 2.1 Bảng Confusion Matrix

		Giá trị thực tế	
		Dương tính	**Âm tính**
Giá trị dự đoán	**Dương tính**	TP	FP
	Âm tính	FN	TN

TP (True positive) là số lượng các trường hợp dự đoán đúng là dương tính hoặc dự đoán đúng với sự thật là dương tính.

TN (True negative) là số lượng các trường hợp dự đoán đúng là âm tính hoặc dự đoán đúng với sự thật là âm tính.

FP (False positive) là số lượng các trường hợp dự đoán sai là dương tính hoặc dự đoán sai với sự thật là âm tính.

FN (False negative) là số lượng các trường hợp dự đoán sai là âm tính hoặc dự đoán sai với sự thật là dương tính.

Từ các khái niệm trên, ta có một số chỉ số đánh giá sau:

Precision: là tỷ lệ số lượng dự đoán dương tính đúng trên tổng số các dự đoán dương tính. Chỉ số precision được tính bằng công thức (2-4):

$$\text{Precision} = \frac{TP}{TP + FP} \tag{2-4}$$

Recall: là tỷ lệ số lượng dự đoán dương tính đúng trên tổng số các trường hợp dương tính thật. Chỉ số này đo lường khả năng của mô hình trong việc phát hiện và dự đoán đúng các trường hợp dương tính. Công thức tính recall là (2-5):

$$\text{Recall} = \frac{TP}{TP+FN} \tag{2-5}$$

Chỉ số F1-score là một phép kết hợp cân đối giữa Precision và Recall. Giá trị F1-score cao chỉ ra rằng mô hình có hiệu suất cao trong việc đảm bảo cả độ chính xác và độ nhạy. Được tính theo công thức (2-6):

$$\text{F1-score} = \frac{2*\text{Precision}*\text{Recall}}{\text{Precision} + \text{Recall}} \tag{2-6}$$

Tùy vào mục đích và độ ưu tiên của từng bài toán, ta có thể dùng các chỉ số khác nhau để đánh giá kết quả dương tính hoặc âm tính. Tuy nhiên, một chỉ số phổ biến và được dùng rộng rãi để đánh giá tổng quát hiệu suất của mô hình là Accuracy.

Accuracy, ta sử dụng công thức (2-7):

$$\text{Accuracy} = \frac{TP + TN}{TP + FP + TN + FN} \tag{2-7}$$

Tùy vào mục đích và độ ưu tiên của từng bài toán, ta có thể dùng các chỉ số khác nhau để đánh giá kết quả dương tính hoặc âm tính. Tuy nhiên, một chỉ số phổ biến và được dùng rộng rãi để đánh giá tổng quát hiệu suất của mô hình là Accuracy.

Confusion Matrix có các ưu điểm sau:

Cung cấp cái nhìn tổng quan về hiệu suất của mô hình trên từng lớp riêng biệt bằng cách cung cấp thông tin về số lượng dự đoán chính xác và sai lầm cho mỗi lớp trong tập dữ liệu. Từ đó giúp xác định khả năng phân loại của mô hình trên các lớp khác nhau.

Cho phép điều chỉnh ngưỡng quyết định để tăng hoặc giảm độ nhạy và độ chính xác của mô hình. Bằng cách thay đổi ngưỡng quyết định, ta có thể điều chỉnh cách mô hình phân loại các dự đoán dương tính và âm tính, tùy thuộc vào mục đích và yêu cầu của bài toán.

Nhược điểm Confusion Matrix là:

Không đưa ra thông tin về chất lượng của dữ liệu mà chỉ cung cấp thông tin về hiệu suất của mô hình trên tập dữ liệu đã có sẵn. Điều này có nghĩa là Confusion Matrix không cho biết liệu dữ liệu được sử dụng để đánh giá mô hình có đủ độ đại diện và độ tin cậy hay không.

Có thể bị ảnh hưởng bởi sự mất cân bằng trong số lượng mẫu giữa các lớp khác nhau, Confusion Matrix có thể bị ảnh hưởng và không phản ánh chính xác hiệu suất của mô hình.

2.4.2 Occlusion Sensitivity Maps

Occlusion Sensitivity Maps (OSMs) là được đề xuất trong bài báo "Visualizing and Understanding Convolutional Networks" của tác giả Matthew D. Zeiler và Rob Fergus (2014) [23]. Bài báo đưa ra phương pháp mới, gọi là Occlusion Sensitivity Maps, để giải thích cách mà các mô hình học sâu xử lý và phân loại hình ảnh. Phương pháp này cho phép quan sát mức độ nhạy cảm của một mô hình đến sự thay đổi của các vật thể trong hình ảnh. OSMs tạo ra bằng cách che phủ các phần của ảnh đầu vào bằng các khối hình vuông và tính toán độ nhạy cảm của mô hình đối với việc che phủ đó. Độ nhạy cảm được tính toán bằng cách so sánh kết quả dự đoán trước và sau khi các phần của ảnh được che phủ. Những bản đồ này cung cấp thông tin về những phần

quan trọng nhất của hình ảnh mà mô hình sử dụng để đưa ra quyết định.

Phương pháp này có thể được áp dụng trong nhiều lĩnh vực như: xử lý ảnh, nhận dạng vật thể và phân loại hình ảnh. OSMs rất hữu ích để phân tích và giải thích cách mà mô hình đưa ra quyết định dựa trên hình ảnh đầu vào.

Cụ thể, OSMs bao gồm các bước sau:

- Chọn vùng muốn kiểm tra: trước tiên, ta chọn một vùng cụ thể trong hình ảnh mà muốn kiểm tra độ nhạy cảm của mô hình với vùng đó.

- Tạo các bản đồ nhạy tắc (occlusion): tạo ra các bản đồ nhạy tắc bằng cách thay đổi vùng muốn kiểm tra bằng các giá trị màu đen hay bất kỳ sao cho nhận diện dễ dàng để thể hiện vật thể bị ẩn đi.

- Chạy giá trị đầu ra mới qua mô hình CNN: đầu vào mới (được kết hợp với các giá trị đen được thêm vào) được chạy qua mô hình CNN và đầu ra mới được tạo ra.

- So sánh giá trị đầu ra mới và ban đầu: ta đối chiếu giá trị đầu ra mới được tạo ra với giá trị ban đầu trước khi thêm giá trị đen vào. Quá trình này giúp xác định xem việc ẩn đi một phần của vật thể có ảnh hưởng đến dự đoán của mô hình hay không..

- Tiếp tục áp dụng quá trình trên cho tất cả các vùng trong hình ảnh: quá trình này được thực hiện lặp lại trên tất cả các vùng của hình ảnh để tạo ra các bản đồ OSMs. Bằng cách che phủ và đánh giá độ nhạy cảm trên từng vùng, chúng ta có thể thu được các bản đồ OSMs cho toàn bộ hình ảnh.

Từ những bước thực hiện trên, OSMs cho phép chúng ta hiểu cách mà mô hình tính toán quan trọng của từng vùng trong hình ảnh. Các vùng được đánh giá là không quan trọng hơn nếu giá trị của OSMs tương ứng với vùng đó là nhỏ. Ngược lại, các vùng được đánh giá là quan trọng hơn nếu giá trị của OSMs tương ứng với vùng dư thừa khá lớn.

2.4.3 Grad-CAM

Grad-CAM [24] là một phương pháp giúp giải thích quyết định của mô hình học sâu

bằng việc tạo ra "bản đồ nhiệt (heat map)" để chỉ ra vị trí quan trọng trên ảnh đóng góp vào kết quả phân loại. Phương pháp này hữu ích trong việc phân tích các mẫu bị phân loại sai và giúp hiểu rõ hơn về cách mà mô hình đưa ra quyết định dựa trên hình ảnh. Chúng ta thường chỉ biết kết quả đầu ra của mô hình mà không biết mô hình đã xem xét những phần nào của ảnh để đưa ra dự đoán. Với Grad-CAM, ta có thể xem xét xác định được những phần của ảnh đã được mô hình tập trung vào để đưa ra kết quả phân loại.

Cụ thể, các bước thực hiện bao gồm:

- Tính độ dốc (gradient) của đầu ra được mong đợi của mô hình theo các đặc trưng đầu vào của ảnh.

- Tính trung bình các gradient theo từng kênh để tạo ra một bản đồ gradient.

- Hợp nhất các bản đồ gradient lại với các trọng số được lấy từ đầu ra mong đợi của mô hình để tạo ra một bản đồ heatmap.

- Cuối cùng, kết hợp heatmap với ảnh ban đầu để tạo ra một ảnh được tô sáng ở các vùng quan trọng.

Ở phần trước tôi có giới thiệu về OSMs, ta thấy OSMs và Grad-CAM đều sử dụng để giải thích và hiểu hành vi của các mô hình học sâu. Tuy vậy, cũng có những sự khác biệt sau:

Bảng 2.2 Bảng so sánh giữa Grad-CAM và OSMs

Grad-CAM	**OSMs**
- Grad-CAM được tạo ra từ việc tích lũy hàm gradient trên đường cong đạo hàm tổng hợp của mạng nơ-ron. Cho phép hiểu hơn về cách tập trung của mô hình vào các vùng quan tâm để đưa ra quyết định. - Dùng để chọn ra các vùng của hình ảnh đóng góp vào quyết định của mô hình, giúp ta hiểu rõ về cách mà mô hình học xử lý các đối tượng.	- Tính độ nhạy của mô hình đối với việc che phủ của khối hình vuông trên mỗi phần của hình ảnh để tìm ra những phần được xem quan trọng nhất của hình ảnh đó. - Được dùng kiểm tra độ tin cậy và hiểu rõ về cơ chế học của mô hình trong việc đưa ra các dự đoán cụ thể.

- Grad-CAM hoạt động tốt khi mô hình có kiến trúc phát triển dựa trên kiểu "global max pooling" - Grad-CAM giải thích cách mà các đặc trưng được xử lý để đưa ra dự đoán của mô hình. - Grad-CAM có thể hoạt động chậm hơn OSMs do phải tính toán gradient và tích lũy trên một số lượng lớn các tầng trung gian.	- OSMs hoạt động tốt trên bất kỳ kiến trúc mô hình nào. - OSMs giải thích cách mà mô hình phân loại các vị trí trên hình ảnh. - OSMs đơn giản và nhanh hơn do chỉ tính toán độ nhạy của mô hình với việc che phủ của hình vuông.

2.4.4 Parameters

Trong quá trình huấn luyện mô hình, các parameters được sử dụng để chỉ định và tối ưu hóa các biến trong mô hình. Parameters thường là các giá trị số được lưu trong ma trận và vector, và chúng được điều chỉnh để giảm thiểu sai lệch giữa kết quả dự đoán của mô hình và giá trị thực tế.

Việc tối ưu các parameters nhằm giúp mô hình học cách suy luận dữ liệu và đưa ra dự đoán chính xác hơn. Số lượng Parameters trong mô hình thường phản ánh độ phức tạp của mô hình và có ảnh hưởng đến khả năng mô hình tổng quát hóa trên các tập dữ liệu mới.

Trong mạng nơ-ron, các parameters bao gồm weights và bias. Weights đại diện cho mức độ quan trọng của mỗi đặc trưng đầu vào đối với dự đoán của mô hình, trong khi bias đóng vai trò trong việc điều chỉnh sai số của dự đoán đầu ra.

Tìm ra các giá trị parameters tối ưu là một quá trình quan trọng trong xây dựng các mô hình học máy và học sâu. Có hai loại Parameters chính là trainable (có thể học được) và non-trainable (không thể học được).