CHƯƠNG 2 ỨNG DỤNG MACHINE LEARNING TRONG PHÂN TÍCH LUỒNG DỮ LIỆU KHÔNG TIN CẬY

2.1 Phân tích các kỹ thuật học máy đã được đề xuất.

Gần đây, sự gia tăng trong việc ứng dụng các thuật toán machine learning vào lĩnh vực an toàn thông tin đã tạo ra một làn sóng nghiên cứu mới, với nhiều công trình đóng góp quan trọng. Đáng chú ý, công trình của Alshammari và Aldribi [1], công bố vào năm 2021, đã khai thác sức mạnh của mạng Neural Networks để phân tích luồng dữ liệu không tin cậy. Mặc dù kỹ thuật này cung cấp khả năng phát hiện chính xác cao, điểm yếu chính của nó nằm ở sự phụ thuộc vào dữ liệu huấn luyện cực kỳ đa dạng và lớn, một điều không luôn luôn khả thi trong môi trường an ninh thực tế . [14]

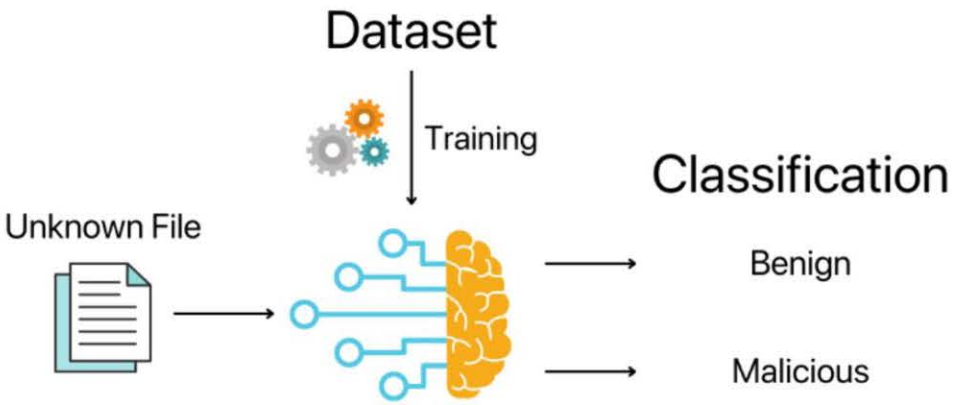

Hình 2.1 Minh họa học máy trong phân loại luồng dữ liệu không tin cậy [14]

Trong một nghiên cứu khác, Fernandez và Xu [2] đã tận dụng sức mạnh của học sâu để phát hiện các biến thể bất thường từ dữ liệu an ninh. Công trình của họ nổi trội nhờ khả năng trích xuất đặc trưng một cách tự động, giảm thiểu nhu cầu về sự can thiệp của con người. Tuy nhiên, nó cũng đòi hỏi tài nguyên tính toán lớn và thời gian huấn luyện dài, điều này gây khó khăn cho việc triển khai nhanh chóng trong các tình huống đòi hỏi phản ứng nhanh.

Đối với công trình của Peng et al. vào năm 2020 [3], đã tiếp cận vấn đề bằng cách áp dụng thuật toán cây quyết định cho hệ thống phát hiện xâm nhập. Cách tiếp cận này cung cấp một sự minh bạch và khả năng giải thích cao cho các quyết định của mô hình, đó là những yếu tố quan trọng trong việc xây dựng lòng tin và hiểu biết về các quy trình tự động. Tuy nhiên, phương pháp này gặp hạn chế trong việc thích nghi với các mô hình tấn công đang phát triển và dữ liệu thay đổi liên tục, yêu cầu sự cập nhật và điều chỉnh liên tục.

Các phương pháp trên cho thấy đạt được nhiều kết quả cao, nhưng đòi hỏi có một bộ dữ lớn trong quá khứ và thời gian huấn luyện lâu. Nhưng trong thực tế các cuộc tấn công diễn ra nhanh chóng, đòi hỏi mô hình đáp ứng được thời gian thực, xử lý bộ dữ không quá lớn, cũng như mang lại hiệu quả cao. Ngoài ra với việc phân loại luồng dữ liệu không tin cậy, bộ dữ liệu tương đối phức tạp, nên sử dụng các phương pháp phân loại cơ bản có nhiều hạn chế trong việc giải quyết các dữ liệu phi tuyến tính. Việc sử dụng một mạng nơ-ron truyền thẳng một lớp ẩn để giải quyết và mang lại hiệu quả về mặt thời gian là một trong nhưng vấn đề cần quan tâm và nghiên cứu.

2.2 Máy học cực trị

Vào năm 2004, dựa trên mô hình nơ-ron truyền thẳng một lớp ẩn, Guang-Bin Huang cùng cộng sự đã đề xuất thuật toán huấn luyện không lặp cho phép pha huấn luyện nhanh hơn gọi là Extreme Learning Machine (máy học cực trị).

Máy học cực trị (Extreme Learning Machine - ELM) là một trong những phương pháp học máy tiên tiến trong lĩnh vực trí tuệ nhân tạo và học máy dựa trên mô hình nơ-ron [11] cụ thể là mô hình nơ-ron một lớp (perceptron) . Nó ra đời nhằm giải quyết các thách thức về tốc độ huấn luyện và hiệu suất mô hình trong các ứng dụng thời gian thực và xử lý dữ liệu lớn. ELM đã trở thành một chủ đề nghiên cứu quan trọng và có ứng dụng rộng rãi trong nhiều lĩnh vực, từ xử lý ảnh đến dự đoán tài chính và điều khiển tự động. Trong luận văn này, sẽ giới thiệu và tìm hiểu chi tiết về máy học cực trị (ELM) và ứng dụng trong việc phân loại luồng dữ liệu không tin cậy.

Extreme Learning Machine (ELM) là một phương pháp học máy có sự đột phá đáng kể trong quá trình huấn luyện mô hình. Nó đã được giới thiệu bởi Guang-Bin Huang, Zhuangwei Zhu, và Chee-Kheong Siew vào năm 2004 [15]. ELM đã nhanh chóng thu hút sự quan tâm của cộng đồng nghiên cứu trong lĩnh vực học máy và trí tuệ nhân tạo nhờ vào hiệu suất cao và tính hiệu quả trong quá trình huấn luyện.

Nguyên tắc cơ bản của ELM là sử dụng một số lượng lớn các nơ-ron ẩn (hidden neurons) trong mạng nơ-ron để biểu diễn dữ liệu đầu vào. Một điểm quan trọng là trọng số và ngưỡng của các nơ-ron ẩn được khởi tạo một cách ngẫu nhiên và không cần được điều chỉnh trong quá trình huấn luyện, điều này giúp ELM nhanh chóng và hiệu quả.

Một mô hình ELM bao gồm hai phần chính: phần đầu vào (input layer) và phần ẩn (hidden layer). Phần đầu vào sẽ nhận dữ liệu đầu vào và truyền chúng đến phần ẩn để xử lý [16].

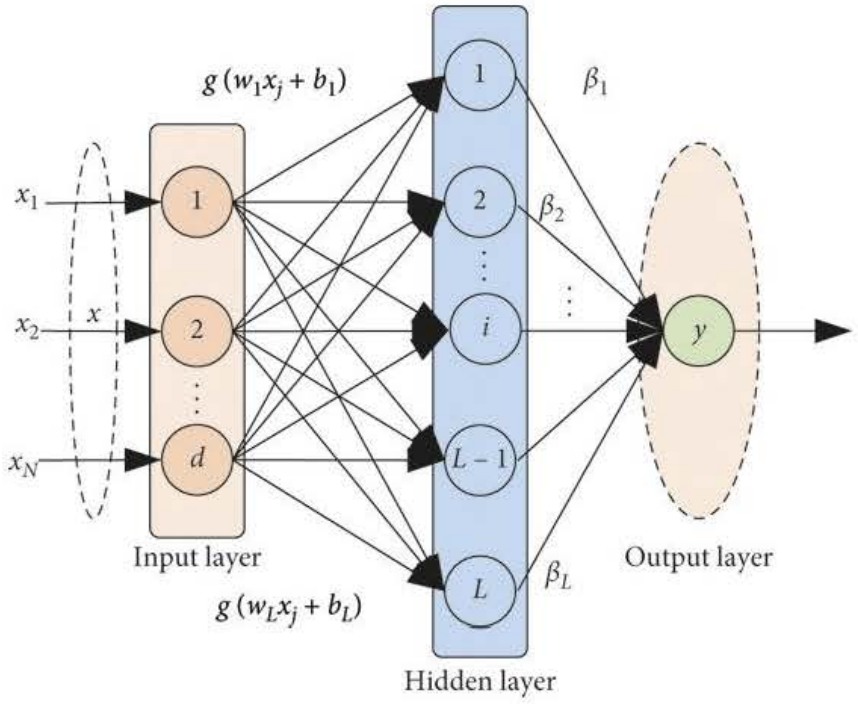

Hình 2.2 Cấu trúc cơ bản Extreme Learning Machine (ELM) [16]

Phần ẩn trong mô hình ELM sử dụng một lượng lớn các nút (nodes) để tạo ra nhiều hàm phi tuyến tính, được mô tả bởi một ma trận trọng số W sinh ngẫu nhiên có k

hàng và d cột, trong đó k là số lượng các nút trong phần ẩn. Và b là một vector chứa giá trị bias có kích thước bằng số số lượng nút ẩn.

Giá trị đầu ra của phần ẩn là H, một ma trận kích thước k x N, được tính bằng cách sử dụng hàm kích hoạt g(x) như sau:

$$H = g(WX + b) \tag{2-1}$$

Sau khi tính toán được phần ẩn H, mô hình tính toán giá trị đầu ra của trọng số $\hat{\beta}$

$$\hat{\beta} = H^{\dagger} y \tag{2-2}$$

Sử dụng nghiệm ẩn $\hat{\beta}$ để dự đoán y mới:

$$y = H\hat{\beta} \tag{2-3}$$

Máy học cực trị có tốc độ huấn luyện nhanh chóng hơn so với nhiều phương pháp khác như mạng nơ-ron sâu (deep neural networks) chỉ đơn giản là một bước: phát triển trọng số giữa các lớp ẩn và lớp đầu ra, không cần quá trình tinh chỉnh tham số như backpropagation trong các mạng nơ-ron sâu. Khi đánh giá với các phương pháp khác, máy học cực trị có độ chính xác cao và tốc độ huấn luyện nhanh với bộ dữ liệu phi tuyến tính, mà các thuật toán máy học cơ bản không thể đem lại ví dụ như thuật toán hồi quy tuyến tính, cây quyết định, SVM [15]… Ngoài ra với môi trường các cuộc tấn công mạng thay đổi liên tục, đòi hỏi mô hình huấn luyện nhanh chóng, đáp ứng ngăn chặn các cuộc tấn công một cách nhanh chóng, trong khi các mô hình mạng học sâu khác thì lại đòi hỏi một lượng dữ liệu lớn trong quá khứ, điều này khiến cho mô hình sẽ không phù hợp trong việc phân loại luồng dữ liệu không tin cậy về mặt thời gian, trong khi máy học cực trị có thể mang hiệu quả ổn định.

2.3 Xây dựng mô hình Extreme Learning Machine

Trong nghiên cứu này chúng tôi tập trung vào việc sử dụng bộ dữ liệu CID-IDS-2017 cho việc xây dựng mô hình để phân loại luồng dữ liệu không tin cậy, Trong đó bộ dữ liệu CID-IDS-2017 được phân tách thành 2 phần theo tỉ lệ cho bộ dữ liệu đào tạo (trainning dataset) và bộ dữ liệu kiểm thử (testing dataset), sử dụng cho việc huấn luyện mô hình, cũng như đánh giá, thông qua nhiều thí nghiệm được thực hiện ở chương 3.

Quá trình huấn luyện mô hình bắt đầu bằng việc áp dụng nhiều kỹ thuật tiền xử lý đối với tập dữ liệu đào tạo, nhằm cải thiện chất lượng và tính khả dụng của dữ liệu. Điều chỉnh cách thức học máy để nhanh chóng đạt được hiệu suất tối ưu cũng là một phần quan trọng của quá trình này. Tiếp theo, tập dữ liệu kiểm thử được sử dụng để kiểm định và đánh giá hiệu suất của mô hình. Mục đích là phát triển một mô hình huấn luyện dựa trên cơ sở của Extreme Learning Machine (ELM), như mô tả trong Hình 2.3. Mô hình được kỳ vọng có thể mang lại hiệu quả trong việc phân tích luồng dữ liệu không tin cậy, đảm bảo tốc độ xử lý nhanh và phù hợp với các tình huống thực tế, tận dụng lợi thế của Extreme Learning Machine (ELM).

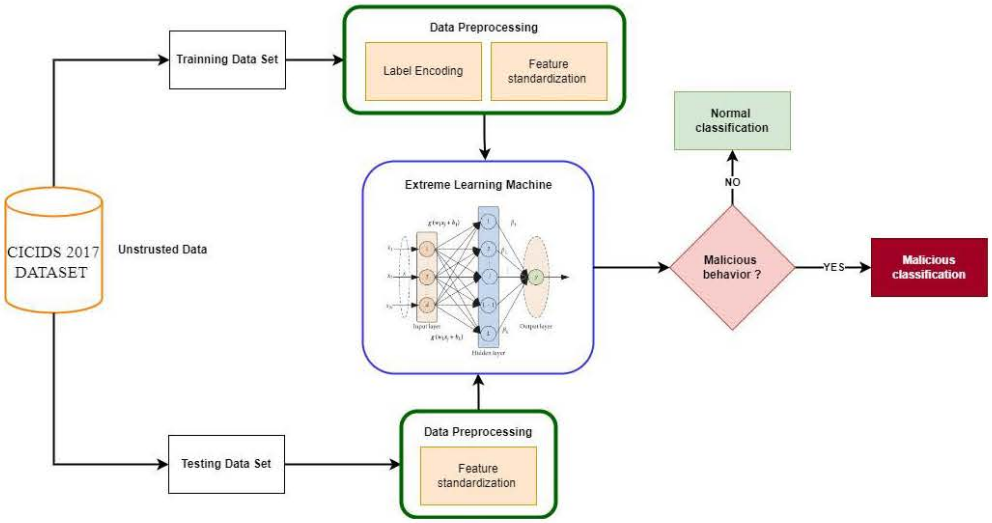

Hình 2.3 Khung mô hình ELM sử dụng bộ dữ liệu CID-IDS-2017