

CHƯƠNG 3 THỰC NGHIỆM VÀ ĐÁNH GIÁ


3.1 Phân tích bộ dữ liệu

Bộ dữ liệu CIC-IDS-2017 [17] là bộ dữ liệu cho nghiên cứu về phát hiện xâm nhập (intrusion detection) trong mạng máy tính, bộ dữ liệu này được tạo ra bởi Canada Institute for Cybersecurity (CIC) và chứa các gói tin mạng thu thập được từ môi trường thực tế. Bộ dữ liệu gồm 5 nhóm xâm nhập, được mô phỏng dựa trên các hành vi của kẻ tấn công.

Bảng 3.1 Phân loại xâm nhập của bộ dữ liệu CID-IDS-2017

STT	Nhóm xâm nhập	Loại xâm nhập
1	Normal	Benign
2	Denial of Service: Dos	Botnet, DDoS, Dos GoldenEye...
3	Password attacks	FTP-Patator, Web attack brute force...
4	Probing	Port Scan
5	Vulnerability	Heartbleed Attack, Web attack sql injection, Web attack XSS

Quá trình thu thập dữ liệu khởi tạo từ lúc 9 giờ sáng thứ hai ngày 3 tháng 7 năm 2017 và kết thúc lúc 5 giờ chiều thứ sáu ngày 7 tháng 7 năm 2017, với tổng thời gian thu thập kéo dài 5 ngày liên tục. Ngày đầu tiên, thứ Hai, được đánh dấu là ngày hoạt động bình thường, với các gói tin được xác định là an toàn. Từ thứ Ba đến thứ Sáu, các cuộc tấn công mạng đã được mô phỏng và thực hiện, diễn ra trong cả hai buổi sáng và chiều, như được minh họa trong Hình 3.1.



Name	Type	Size
Friday-WorkingHours-Afternoon-DDos.pcap_ISCX.csv	Microsoft Excel C...	75,317 KB
Friday-WorkingHours-Afternoon-PortScan.pcap_ISCX.csv	Microsoft Excel C...	75,104 KB
Friday-WorkingHours-Morning.pcap_ISCX.csv	Microsoft Excel C...	56,950 KB
Monday-WorkingHours.pcap_ISCX.csv	Microsoft Excel C...	172,782 KB
Thursday-WorkingHours-Afternoon-Infiltration.pcap_ISCX.csv	Microsoft Excel C...	81,155 KB
Thursday-WorkingHours-Morning-WebAttacks.pcap_ISCX.csv	Microsoft Excel C...	50,804 KB
Tuesday-WorkingHours.pcap_ISCX.csv	Microsoft Excel C...	131,914 KB
Wednesday-workingHours.pcap_ISCX.csv	Microsoft Excel C...	219,890 KB

Hình 3.1 Tập dữ liệu của bộ dữ liệu CID-IDS-2017


), tốc độ truyền dữ liệu (Flow Bytes/s), tốc độ truyền gói tin (Flow Packets/s), nhãn phân loại dữ liệu (label).

Bảng 3.2 Tóm tắt các thuộc tính trong bộ dữ liệu CID-IDS-2017

STT	Tên thuộc tính	Mô Tả
1	Destination Port (Port đích)	Đây là số cổng đích mà giao dịch mạng được gửi tới. Nó xác định cổng mà máy chủ hoặc dịch vụ đang lắng nghe.
2	Protocol (Giao thức)	Giao thức mạng được sử dụng trong giao dịch, ví dụ: TCP, UDP, ICMP.
3	Flow Duration (Thời gian luồng)	Thời gian (tính bằng giây) từ khi bắt đầu giao dịch cho đến khi kết thúc.
4	Total Fwd Packets (Tổng số gói tin chuyển tiếp)	Số lượng gói tin được chuyển tiếp nguồn đến đích.
5	Total Backward Packets (Tổng số gói tin gửi lại)	Số lượng gói tin được gửi từ đích đến nguồn.
6	Total Length of Fwd Packets	Tổng độ dài gói tin chuyển tiếp
7	Total Length of Bwd Packets	Tổng độ dài của tất cả các gói tin gửi lại
8	Fwd Packet Length Max	Độ dài tối đa của gói tin chuyển tiếp
9	Bwd Packet Length Max	Độ dài tối đa của gói tin gửi lại
10	Flow Bytes/s	Tốc độ truyền dữ liệu trong luồng, được tính bằng cách chia tổng độ dài của gói tin cho thời gian luồng.
11	Fwd IAT Total	Tổng thời gian giữa các gói tin chuyển tiếp.
12	Bwd IAT Total	Tổng thời gian giữa các gói tin gửi lại.
13	Label	Thông tin nhãn, Các giá trị thường gặp là " Benign" (Bình thường) hoặc tên của các loại tấn công mạng như infiltration, web attack brute force, web attack xss, web attack sql injection...
...	...	...

Sự liên quan dữ liệu được thể hiện thông qua biểu đồ nhiệt ở Hình 3.4, cho thấy một số thuộc tính của bộ dữ liệu CID-IDS-2017 có mối quan hệ rất mạnh với nhau, ví dụ như "Total Length of Fwd Packets" và "Total Fwd Packets" có mối quan hệ gần như hoàn hảo với giá trị tương quan 0.99. Điều này có thể chỉ ra rằng hai đặc trưng này


mang thông tin tương tự nhau hoặc rất tương quan mật thiết, điều này có thể ảnh hưởng đến mô hình học máy nếu cả hai đặc trưng được sử dụng, vì nó có thể gây ra hiện tượng đa cộng tuyến (Multicollinearity).



Hình 3.4 Biểu đồ tương quan các thuộc tính trong CID-IDS-2017

Ngược lại, các đặc trưng như "Flow Duration" và "Destination Port" có mối quan hệ rất yếu với nhau, chỉ ra rằng chúng có thể đại diện cho các thông tin độc lập trong dữ liệu. Việc sử dụng các thông tin độc lập có thể mang lại một số hiệu quả hữu ích cho việc huấn luyện mô hình và mang độ tính xác hơn.

Xem xét biểu đồ trực quan boxplot ở Hình 3.5 thể hiện sự khác nhau về mặt thời gian luồng (flow duration) của 2 phân lớp dữ liệu, cho thấy rằng với luồng dữ liệu bình thường (normal), thời gian luồng (flow duration) có xu hướng ngắn hơn và có ít biến động hơn so với dữ liệu không an toàn (malicious). Chứng minh rằng việc sử dụng thời gian luồng là một thông tin độc lập có thể hữu ích trong việc huấn luyện học máy.




Hình 3.5 Mô hình thể hiện flow duration cho normal và malicious

3.2 Các phương pháp đánh giá hiệu suất mô hình

Để đánh giá hiệu suất của mô hình học máy, chúng tôi thường sử dụng một loạt các chỉ số đánh giá quan trọng như độ chính xác (accuracy), độ phủ (recall), và độ chính xác dương tính (precision) [18]. Các chỉ số này giúp chúng tôi đo lường khả năng của mô hình trong việc phân loại dữ liệu.

Độ chính xác (Accuracy): đây là một chỉ số quan trọng để đo lường tỷ lệ phần trăm của các dự đoán đúng trên tổng số dự đoán. Độ chính xác được tính bằng cách chia số lượng mẫu được phân loại chính xác cho tổng số mẫu. Nó cung cấp một cái nhìn tổng quan về khả năng phân loại của mô hình.

$$accuracy = \frac{\sum_{i=1}^n [y_i = \hat{y}_i]}{n} \quad (3-1)$$



Hình 3.6 Minh họa độ chính xác dương tính và độ phủ [19]

Độ phủ (Recall): độ phủ đo lường khả năng của mô hình trong việc bắt kịp tất cả các trường hợp dương thực sự (thường là các trường hợp quan trọng mà bạn muốn phát hiện). Nó được tính bằng cách chia số lượng trường hợp dương thực sự được phân loại đúng cho tổng số trường hợp dương thực sự.

$$Recall = \frac{TP}{TP+FN} \quad (3-2)$$

Độ chính xác dương tính (Precision): độ chính xác dương tính đo lường khả năng của mô hình trong việc đưa ra các dự đoán dương tính đúng. Nó được tính bằng cách chia số lượng trường hợp dương thực sự được phân loại đúng cho tổng số trường hợp được phân loại dương tính.

$$Precision = \frac{TP}{TP+FP} \quad (3-3)$$

Độ đo F1-score là trung bình điều hòa giữa độ chính xác dương tính và độ phủ, nó đo lường sự cân nhắc giữa độ chính xác và độ nhạy của mô hình trong việc dự đoán đúng các trường hợp dương tính. Giá trị F1-score cao chỉ ra rằng mô hình có hiệu suất cao trong việc đảm bảo cả độ chính xác và độ nhạy. Được tính bằng công thức.

$$F1 - score = \frac{2(precision*recall)}{precision+recall} \quad (3-4)$$

Ngoài ra chúng tôi còn lập ma trận tương quan (Confusion matrix), đây là một công cụ quan trọng trong việc đánh giá kết quả của các bài toán phân loại, Nó cung cấp một cái nhìn tổng quan về độ chính xác và độ bao phủ của từng lớp phân loại, đồng

thời giúp tính toán các chỉ số đánh giá khác nhau dựa trên sự kết hợp của các giá trị dự đoán và thực tế. Nó được thể hiện theo bảng dưới

Bảng 3.3 Bảng tính toán ma trận tương quan (Confusion Matrix)

	Predicted as Positive	Predicted as Negative
Actual: Positive	True Positive (TP)	False Negative (FN)
Actual: Negative	False Positive (FP)	True Negative (TN)

Ý nghĩa các giá trị:

- TP (True positive) là số lượng các trường hợp dự đoán đúng là dương tính hoặc dự đoán đúng với sự thật là dương tính.
- TN (True negative) là số lượng các trường hợp dự đoán đúng là âm tính hoặc dự đoán đúng với sự thật là âm tính.
- FP (False positive) là số lượng các trường hợp dự đoán sai là dương tính hoặc dự đoán sai với sự thật là âm tính.
- FN (False negative) là số lượng các trường hợp dự đoán sai là âm tính hoặc dự đoán sai với sự thật là dương tính.

Các chỉ số này cùng nhau giúp chúng tôi hiểu rõ hơn về hiệu suất của mô hình trong việc phân loại dữ liệu và xác định khả năng của nó trong việc phát hiện các trường hợp quan trọng. Chúng tôi sử dụng chúng để đảm bảo rằng mô hình của mình đáp ứng được các yêu cầu đề ra.

Mô hình tương quan chỉ cung cấp thông tin về cách mà mô hình hoạt động trên tập dữ liệu đã được cung cấp. Chất lượng của dữ liệu đóng vai trò quan trọng trong việc xác định xem liệu mô hình có thể tổng quát hóa tốt trên dữ liệu mới hay không. Nếu dữ liệu huấn luyện không đại diện cho thực tế hoặc chứa nhiễu lớn, mô hình có thể không hoạt động tốt trên dữ liệu thực tế và không có độ tin cậy cao.

Mô hình tương quan cũng sẽ gây nhầm lẫn do việc ảnh hưởng bởi sự mất cân bằng số lượng mẫu giữa các lớp khác nhau, không đưa ra kết quả chính xác cho việc đánh giá hiệu suất của mô hình.

3.3 Công cụ và môi trường

Môi trường sử dụng để huấn luyện mô hình bao gồm một máy tính với cấu hình như sau:

- Bộ vi xử lý (CPU): Intel i7-10750H CPU @ 2.6GHz
- Bộ nhớ RAM: 24GB.
- Card đồ họa (GPU): NVIDIA GTX 1650.
- Ổ cứng: SSD dung lượng 512GB.
- Hệ điều hành: Windows 10 pro-64-bit.

Ngôn ngữ lập trình Python 3.7.8, dựa trên nền tảng Anaconda, sử dụng jupyter để quản lý và chạy thử nghiệm.

3.4 Phương thức

3.4.1 Tiền xử lý dữ liệu

Tiền xử lý dữ liệu đóng một vai trò quan trọng trong lĩnh vực khoa học dữ liệu và học máy, đặc biệt khi xem xét bộ dữ liệu Intrusion Detection Evaluation Dataset (CIC-IDS-2017). Bộ dữ liệu này liên quan đến vấn đề dữ liệu mạng và có những đặc thù riêng, yêu cầu quá trình tiền xử lý tập trung vào nhiều khía cạnh quan trọng như sau:

- Xử lý dữ liệu nhiễu, dữ liệu dư thừa, và mất thông tin: dữ liệu mạng thường bị nhiễu vì nhiều nguyên nhân như sự cố kỹ thuật, sai sót trong quá trình ghi dữ liệu, hoặc các tình huống không mong muốn. Quá trình tiền xử lý dữ liệu cần tập trung vào xác định và loại bỏ các tín hiệu nhiễu này để đảm bảo tính chính xác và đáng tin cậy của dữ liệu. Chúng tôi thấy rằng có khoảng 45761 trường hợp dữ liệu bị trùng lặp và 38 giá trị bị thiếu data nằm ở thuộc tính Flow Bytes/s, trong trường hợp này chúng tôi xóa các cặp trùng lặp, và các dữ liệu thiếu data.
- Mã hóa nhãn dữ liệu: bộ dữ liệu CIC-IDS-2017 bao gồm cả dữ liệu về các sự kiện tấn công mạng và dữ liệu bình thường. Chúng tôi sử dụng cơ chế mã

hóa dữ liệu thành 2 lớp là dữ liệu an toàn (normal) và dữ liệu không an toàn (malicious) lần lượt với giá trị 0 và 1.

- Chuẩn hóa dữ liệu: Để đảm bảo tính thống nhất và đồng nhất trong dữ liệu, quá trình tiền xử lý bao gồm việc chuẩn hóa dữ liệu, tránh việc sai lệch của dữ liệu, trong nghiên cứu này chúng tôi tập trung vào chuẩn hóa standardization, ngoài ra chúng tôi còn thực nghiệm các chuẩn hóa khác để đánh giá sự ảnh hưởng của việc chuẩn hóa trong phần thực nghiệm bên dưới.

Quá trình tiền xử lý dữ liệu trong trường hợp này đóng vai trò then chốt trong việc chuẩn bị dữ liệu trước khi áp dụng các thuật toán học máy, và nó đóng góp đáng kể vào việc tối ưu hóa và cải thiện độ chính xác của quá trình huấn luyện và đánh giá mô hình.

3.4.2 Xử lý cân bằng mất cân bằng dữ liệu

Kích thước bộ dữ liệu là 170366, trong đó 162036 dữ liệu ở trạng thái an toàn, 2143 ở trạng thái không an toàn. Tỷ lệ kích thước của dữ liệu an toàn so với dữ liệu không an toàn có một sự chênh lệch quá cao gây ra vấn đề mất cân bằng dữ liệu trong việc huấn luyện mô hình, điều này gây ảnh hưởng kết quả huấn luyện. Để giải quyết vấn đề mất cân bằng sử dụng kỹ thuật tái mẫu và tăng cường mẫu dữ liệu không an toàn thông qua việc sử dụng thư viện Imbalanced-learn viết bằng ngôn ngữ python.


Sau khi xử lý chúng tôi ghi nhận được kích thước bộ dữ liệu là 324072 trong đó dữ liệu an toàn là 162036, và 162036 ở trạng thái không an toàn.

3.4.3 Thực nghiệm và Đánh giá kết quả

Để đảm bảo tính chính xác trong việc đánh giá và đo lường hiệu quả của máy học cực trị trong quá trình huấn luyện bộ dữ liệu, chúng tôi đã tiến hành nhiều thí nghiệm khác nhau thông qua các độ đo khác nhau để đánh giá mức độ hiệu quả máy học cực trị ELM.

Trong khuôn khổ thí nghiệm đầu tiên, chúng tôi đã triển khai thuật toán ELM với số lượng ẩn và hàm kích hoạt khác nhau theo thứ tự như Hình 3.7 và Bảng 3.4, phân

chia dữ liệu thành 80% cho dữ liệu huấn luyện và 20% cho dữ liệu thử nghiệm, áp dụng bộ chuẩn hóa dữ liệu tiêu chuẩn, hàm kích hoạt tanh và sigmoid cho thấy độ chính xác chiếm ưu thế hơn, hàm relu và leak-relu thì không có quá nhiều thay đổi.



Hình 3.7 Biểu đồ so sánh kết quả theo số lượng ẩn với hàm kích hoạt khác nhau

Về độ chính xác tương ứng với từng số lượng ẩn khác nhau của từng hàm kích hoạt cho thấy có sự thay đổi không quá chênh lệch, hàm sigmoid có xu hướng độ chính xác tăng khi số lượng ẩn tăng. Tương tự với hàm relu và leaky relu cho thấy có sự biến thiên về độ chính xác không ổn định. Điều này cho thấy hàm sigmoid là lựa chọn tốt nhất để huấn luyện mô hình.

Bảng 3.4 Kết quả huấn luyện theo số lượng ẩn với hàm kích hoạt khác nhau

		Hidden Quantity				
		50	250	450	750	950
Activation Functions	Sigmoid	0.927	0.955	0.961	0.966	0.966
	Tanh	0.889	0.937	0.950	0.956	0.957
	Relu	0.536	0.537	0.538	0.539	0.564
	Leaky_relu	0.532	0.531	0.531	0.532	0.558

Trong thí nghiệm thứ 2, chúng tôi duy trì cùng một bộ quy tắc chuẩn hóa tiêu chuẩn và số lượng ẩn cố định là 50 với hàm kích hoạt sigmoid, với các phương pháp khác sử dụng theo cấu hình mặc định, chúng tôi muốn đánh giá tốc độ và độ chính xác

của máy học cực trị so với các phương pháp học máy khác như hồi quy tuyến tính (Logistic Regression), phân loại rừng ngẫu nhiên (Random Forest Classifier - RFC)

Bảng 3.5 Kết quả so sánh tốc độ và chính xác của các phương pháp

	Accuracy	Time (s)
ELM	0.92	0.86
Logistic Regression	0.98	3.81
Random Forest Classifier	1	25.75

Thí nghiệm cho thấy về tốc độ huấn luyện máy học cực trị (ELM) thể hiện tốc độ huấn luyện nhanh với kết quả đạt 0.08 giây, hồi quy tuyến tính đạt 3.81 giây và cây rừng ngẫu nhiên đạt 25.75 giây, nhưng độ chính thì ELM chỉ đạt 0.92. Điều này thể hiện, ELM mang lại hiệu quả cao về mặt thời gian huấn luyện.


Trong thí nghiệm thứ 3, chúng tôi duy trì cùng một bộ quy tắc chuẩn hóa tiêu chuẩn và số lượng ẩn cố định là 250, chúng tôi thực hiện đánh giá mô hình qua 2 phương pháp là cross-validation được minh họa trong Bảng 3.6, và split-validation trong Bảng 3.7, hai phương pháp được áp dụng qua bốn hàm kích hoạt khác nhau: sigmoid, tanh, relu và leaky_relu nhằm đưa ra sự so sánh giữa chúng về sự ảnh hưởng đến khả năng dự đoán của mô hình.

Bảng 3.6 Kết quả độ đo cho phương pháp cross validation với số ẩn 250

		Value of K fold		
		5	10	15
Activation Functions	Sigmoid	0.96	0.96	0.96
	Tanh	0.94	0.94	0.94
	Relu	0.54	0.54	0.54
	Leaky_relu	0.53	0.53	0.53

Đối với Bảng 3.6, chúng tôi đã thực hiện các thí nghiệm với kích thước k của k-fold cross-validation là 5, 10 và 15. Kết quả cho thấy độ chính xác của các folds của từng hàm kích hoạt không có sự thay đổi, hàm sigmoid và tanh vẫn cho thấy chiếm ưu chế cao đạt độ chính xác từ 0.94 trở lên, hàm kích hoạt relu và hàm kích hoạt leaky relu chỉ đạt khoảng 0.53. Mặt khác trong Bảng 3.7 và Hình 3.8, phương pháp split-validation cho thấy hàm kích hoạt sigmoid và tanh vẫn mang lại độ chính xác

ổn định hơn so với các hàm khác, khi thay đổi tỷ lệ phần trăm của tập dữ liệu đào tạo của các hàm kích hoạt không có sự khác biệt quá lớn.



Hình 3.8 Biểu đồ thể hiện sự thay đổi theo phương pháp split validation

Bảng 3.7 Kết quả độ đo cho phương pháp split validation với số ẩn 150

		Splitting (%) (Training dataset)			
		50	60	70	80
Activation Functions	Sigmoid	0.958	0.958	0.957	0.958
	Tanh	0.936	0.939	0.935	0.939
	Relu	0.537	0.539	0.540	0.541
	Leaky_relu	0.529	0.531	0.534	0.534

Để có một cái đánh giá tốt hơn về hiệu quả của các mô hình, chúng ta cần xem xét thêm các độ đo khác nhau như độ phủ (recall), trung bình điều hòa giữa độ chính xác dương tính và độ phủ (f1-score).

Bảng 3.7 và Bảng 3.8, minh họa huấn luyện mô hình với kích thước 80% dữ liệu cho tập đào tạo, cấu hình với số lượng ẩn là 150. Kết quả cho thấy, khi áp dụng hàm kích hoạt sigmoid và hàm kích hoạt tanh mô hình đạt độ chính xác dương tính tương đối cao, với độ chính xác dương tính khi sử dụng hàm sigmoid cho dữ liệu độc hại là 0.96 và độ phủ là 0.94 với 30,245 trường hợp được dự đoán chính xác trong tổng số 30,249. Bên cạnh đó hàm kích hoạt relu và hàm kích hoạt leaky relu có độ chính xác dương tính cao khi phân loại luồng dữ liệu độc hại, nhưng độ phủ

chỉ đạt dưới 0.08. Điều này chứng tỏ mô hình máy học cực trị hoạt động tốt khi sử dụng hàm kích hoạt sigmoid và hàm kích hoạt tanh với tỉ lệ bỏ sót không đáng kể.

Bảng 3.8 Độ tương quan độ đo giữa hàm kích hoạt khác nhau với số ẩn 250

		Label	Precision	Recall	F1-score
Activation Functions	Sigmoid	0 (normal)	0.94	0.98	0.96
		1 (malicious)	0.98	0.94	0.96
	Tanh	0 (normal)	0.92	0.96	0.94
		1 (malicious)	0.96	0.91	0.94
	Relu	0 (normal)	0.52	0.99	0.69
		1 (malicious)	0.96	0.08	0.15
	Leaky_Relu	0 (normal)	0.52	0.98	0.68
		1 (malicious)	0.86	0.08	0.15

Bảng 3.9 Độ tương quan dữ liệu hàm kích hoạt khác nhau với số ẩn 250

			Predicted normal	Predicted malicious
Activation Functions	Sigmoid	0 (normal)	TP (31,878)	FP (654)
		1 (malicious)	FN (1,969)	TN (30,245)
	Tanh	0 (normal)	TP (31,403)	FP (695)
		1 (malicious)	FN (2,746)	TN (29,468)
	Relu	0 (normal)	TP (32,390)	FP (124)
		1 (malicious)	FN (29,532)	TN (2,682)
	Leaky_Relu	0 (normal)	TP (31,991)	FP (430)
		1 (malicious)	FN (29,580)	TN (2,634)

Dựa trên kết quả ẩn tượng của hàm tanh trong thí nghiệm trước, chúng tôi tiến hành thực nghiệm thí nghiệm 3 với mục tiêu nâng cao chất lượng dữ liệu đầu vào. Bằng cách áp dụng các phương pháp chuẩn hóa dữ liệu như Standardization, Robust và Min-Max, chúng tôi mong muốn đánh giá mức độ ảnh hưởng tới độ chính xác và hiệu quả của mô hình và xác định phương pháp chuẩn hóa tối ưu thể hiện trong Bảng 3.10.

Bảng 3.10 Bảng tương quan độ đo với số quy tắc chuẩn hóa khác nhau

Scaling	Label	Precision	Recall	F1-score
Standardization	0 (normal)	0.94	0.98	0.96
	1 (malicious)	0.98	0.94	0.96
Robust Scaling	0 (normal)	0.88	1	0.93
	1 (malicious)	1	0.86	0.92
Min-Max Scaling	0 (normal)	0.9	0.98	0.98
	1 (malicious)	0.98	0.99	0.99

Kết quả thực nghiệm cho thấy, phương pháp chuẩn hóa Min-Max mang lại độ chính xác cao trong việc phân loại luồng dữ liệu không tin cậy. Với phương pháp Robust Scaling việc phân loại dữ liệu độc loại đạt được kết quả cao 100%, nhưng độ phủ chỉ đạt có 85%.

KẾT LUẬN VÀ KIẾN NGHỊ

Luận văn này đã cung cấp một cái nhìn tổng quan về các thách thức do luồng dữ liệu không tin cậy gây ra trong lĩnh vực an toàn thông tin, xem xét các công trình học máy được ứng dụng trước đó. Qua quá trình nghiên cứu, chúng tôi đã thực hiện đánh giá và phân tích các khía cạnh thực tiễn liên quan, và đã đề xuất ứng máy học cực trị (ELM), giải quyết được vấn đề liên quan đến dữ liệu và thời gian thực.

Kết quả thí nghiệm của chúng tôi chứng minh phương pháp này đem lại nhiều ưu điểm vượt trội, kết quả đạt được kỳ vọng cao, hiệu quả trong việc phân loại luồng dữ liệu không tin cậy, đồng thời có khả năng huấn luyện mô hình một cách nhanh chóng với độ chính xác cao mà không đòi hỏi một lượng lớn dữ liệu phức tạp, phù hợp với sự thay đổi nhanh chóng của luồng dữ liệu không tin cậy, dễ dàng ứng dụng vào các sản phẩm mang tính chất cần thời gian thực,

Bên cạnh, chúng tôi còn nhiều vấn đề chưa giải quyết trong việc đánh giá các bộ dữ liệu khác nhau, đưa ra một mô hình tốt cho từng loại dữ liệu khác nhau, và áp dụng thực tế trong môi trường không gian mạng.

Trong tương lai, chúng tôi mong muốn mở rộng ứng dụng của phương pháp này cho các vấn đề khác trong an ninh thông tin, như việc phát hiện mã độc và các hoạt động bất thường trên không gian mạng. Chúng tôi cũng kỳ vọng vào việc phát triển và tích hợp phương pháp này vào các ứng dụng hoặc hệ thống phát hiện xâm nhập (IDS), nhằm cải thiện khả năng nhận diện thông tin một cách chính xác hơn.

TÀI LIỆU THAM KHẢO

- [1] A. Alshammari and A. Aldribi. "Apply machine learning techniques to detect malicious network traffic in cloud computing," *Journal of Big Data*. Vol. 8, no. 1, pp. 1-24, 2021.
- [2] G. C. Fernández and S. Xu. "A case study on using deep learning for network intrusion detection," in *MILCOM 2019-2019 IEEE Military Communications Conference (MILCOM)*, 2019.
- [3] K. Peng *et al.* "Intrusion detection system based on decision tree over big data in fog environment," *Wireless Communications and Mobile Computing*. Vol. 2018, pp. 1530-8669, 2018.
- [4] Positive Technologies. "Web Applications vulnerabilities and threats: statistics for 2019." 2020. [Online]. Available: <https://www.ptsecurity.com/ww-en/analytics/web-vulnerabilities-2020/>.
- [5] R. L. Alaoui and E. H. Nfaoui. "Deep learning for vulnerability and attack detection on web applications: A systematic literature review," *Future Internet*. Vol. 14, no. 4, p. 118, 2022.
- [6] M. Schlenker. "Intrusion Detection," [Online]. Available: <https://www.omscs-notes.com/information-security/intrusion-detection/>.
- [7] M. Zamani and M. Movahedi. "Machine learning techniques for intrusion detection," *arXiv preprint arXiv:1312.2177*, 2013.
- [8] M. H. Thwaini. "Anomaly Detection in Network Traffic using Machine Learning for Early Threat Detection," *Data and Metadata*. Vol. 1, pp. 34-34, 2022.
- [9] Shiksha Online. "Perceptron Model: The Foundation of Neural Networks." [Online]. Available: <https://medium.com/@ilyurek/perceptron-model-the-foundation-of-neural-networks-4db25b0148d/>.
- [10] Rajat Gupta. "Getting started with Neural Network for regression and Tensorflow." [Online]. Available: <https://medium.com/@rajatgupta310198/getting-started-with-neural-network-for-regression-and-tensorflow-58ad3bd75223>.
- [11] G.-B. Huang *et al.* "Extreme learning machine: a new learning scheme of feedforward neural networks," in *2004 IEEE international joint conference on neural networks (IEEE Cat. No. 04CH37541)*, 2004.
- [12] Thaddeus. "Feature Scaling ." [Online]. Available: <https://thaddeus-segura.com/feature-scaling/>.
- [13] Shiksha Online. "Activation Functions: With Real-life analogy and Python Code." 5 10 2023. [Online]. Available: <https://www.shiksha.com/online-courses/articles/activation-functions-with-real-life-analogy-and-python-code/>.
- [14] SOCRadar. "Real-Life Examples of Machine Learning in Cybersecurity." 2 5 2023. [Online]. Available: <https://socradar.io/real-life-examples-of-machine-learning-in-cybersecurity/>.
- [15] G.-B. Huang *et al.* "Extreme learning machine: theory and applications," *Neurocomputing*. Vol. 70, no. 1-3, pp. 489-501, 2006.

- [16] S. Zang *et al.* "Transfer extreme learning machine with output weight alignment," *Computational Intelligence and Neuroscience*. Vol. 2021, pp. 1-14, 2021.
- [17] University of New Brunswick. "Intrusion Detection Evaluation Dataset (CIC-IDS2017)." [Online]. Available: <https://www.unb.ca/cic/datasets/ids-2017.html>.
- [18] V. H. Tiệp. "Bài 33: Các phương pháp đánh giá một hệ thống phân lớp." [Online]. Available: <https://machinelearningcoban.com/2017/08/31/evaluation/>.
- [19] Edge AI and Vision Alliance. "Precision and Recall for Time Series." [Online]. Available: <https://www.edge-ai-vision.com/2019/01/precision-and-recall-for-time-series/>.